

MÉTRICAS DE AVALIAÇÃO NO PYCARET (CLASSIFICAÇÃO)

Métrica	O que mede	Quando usar	Exemplo prático
Accuracy	Mostra a proporção de previsões corretas em relação ao total de amostras.	Quando o conjunto de dados está balanceado entre classes.	Classificação de tipos de flores (dataset Iris).
AUC (Area Under Curve)	Mede a capacidade do modelo de distinguir entre classes positivas e negativas.	Para comparar classificadores e avaliar modelos probabilísticos.	Avaliar a qualidade de um modelo que prevê câncer benigno ou maligno.
Recall (Sensibilidade)	Indica quantos casos positivos reais foram corretamente identificados.	Quando é importante detectar todos os casos positivos.	Diagnóstico de doenças (evitar falsos negativos).
Precision (Precisão)	Mostra quantos dos casos classificados como positivos realmente eram positivos.	Quando o erro de falso positivo é mais grave.	Detecção de fraudes em cartões de crédito.
F1-Score	Combina precisão e recall em uma única métrica de equilíbrio.	Quando há desequilíbrio entre classes.	Classificação de e-mails como "spam" ou "não spam".
Kappa (Cohen's Kappa)	Mede a concordância entre as previsões e os valores reais, descontando o efeito do acaso.	Quando se quer avaliar a confiabilidade do modelo.	Comparar decisões de um modelo com diagnósticos feitos por médicos.
MCC (Matthews Corr. Coefficient)	Mede a correlação entre valores previstos e reais considerando todos os tipos de erro.	Em conjuntos de dados desbalanceados, pois é mais estável.	Detecção de defeitos raros em produtos industriais.
Log Loss (Logarithmic Loss)	Avalia o quão confiantes e corretas são as probabilidades previstas pelo modelo.	Quando o modelo gera probabilidades em vez de rótulos diretos.	Modelos de previsão de churn (clientes propensos a cancelar um serviço).

PAINEL DE AVALIAÇÃO DO PYCARET

Cada opção exibida no comando `evaluate_model()` representa um tipo de análise visual do desempenho do modelo. A tabela abaixo explica, de forma simples e didática, a função de cada gráfico.

Opção	Descrição e finalidade
Pipeline Plot	Mostra o pipeline completo usado pelo PyCaret (pré-processamentos aplicados, como normalização, codificação, imputação, etc.). Útil para entender o fluxo de dados até o modelo.
Class Report	Exibe as principais métricas de desempenho (Accuracy, Precision, Recall, F1-Score, Kappa, MCC) para cada classe, em formato tabular.
Feature Importance	Mostra graficamente quais variáveis (features) têm maior impacto nas previsões do modelo.
Hyperparameters	Lista os valores dos hiperparâmetros utilizados pelo modelo (ex.: profundidade de árvore, número de estimadores, taxa de aprendizado, etc.).
Feature Selection	Mostra o subconjunto de variáveis que o modelo considerou mais relevante após o processo de seleção automática de features.
AUC (ROC Curve)	Exibe a curva ROC e calcula a área sob a curva (AUC), medindo a capacidade do modelo em distinguir entre classes.
Learning Curve	Mostra a relação entre o tamanho do conjunto de treino e o desempenho do modelo, ajudando a detectar overfitting ou underfitting.
Decision Boundary	Mostra como o modelo separa graficamente as classes (apenas para datasets com 2 features).
Confusion Matrix	Exibe a matriz de confusão, que mostra quantos casos o modelo classificou corretamente e onde cometeu erros (falsos positivos e negativos).
Manifold Learning	Projeção 2D (via PCA/t-SNE) para visualizar como as classes estão distribuídas no espaço de atributos.
Lift Chart	Mostra o ganho relativo do modelo em relação a uma predição aleatória. Muito usado em marketing e segmentação de clientes.
Threshold	Permite ajustar o limiar de decisão da probabilidade e observar o impacto nas métricas de desempenho.
Calibration Curve	Verifica se as probabilidades previstas refletem corretamente as probabilidades reais (calibração do modelo).
Gain Chart	Mostra o ganho acumulado do modelo — quanto ele melhora a detecção de casos positivos em relação ao acaso.
Precision Recall	Exibe a curva de precisão vs. recall, útil especialmente em conjuntos de dados desbalanceados.
Validation Curve	Mostra como o desempenho muda em função de um hiperparâmetro específico, ajudando a identificar o ponto ideal.
Decision Tree	Exibe uma das árvores do modelo, permitindo visualizar como o modelo toma decisões.
Prediction Error	Mostra os erros de predição — quanto as saídas previstas se afastam dos valores reais.
Dimensions	Reduz a dimensionalidade (via PCA/t-SNE) para visualizar a distribuição dos dados e a separação entre classes.
KS Statistic Plot	Exibe o Kolmogorov–Smirnov statistic, usado para medir o poder discriminativo do modelo (comum em modelos de crédito e risco bancário).