



UNITINS
UNIVERSIDADE ESTADUAL DO TOCANTINS

TOCANTINS
GOVERNO DO ESTADO



CURSO SISTEMAS DE INFORMAÇÃO

SISTEMA DE RECOMENDAÇÃO FINANCEIRA PESSOAL INTELIGENTE BASEADO EM AGENTES DE IA PARA MITIGAÇÃO DE GASTOS DESNECESSÁRIOS

JOÃO VICTOR PÓVOA FRANÇA

PALMAS

2025



UNITINS
UNIVERSIDADE ESTADUAL DO TOCANTINS

TOCANTINS
GOVERNO DO ESTADO



**SISTEMA DE RECOMENDAÇÃO FINANCEIRA PESSOAL INTELIGENTE
BASEADO EM AGENTES DE IA PARA MITIGAÇÃO DE GASTOS
DESNECESSÁRIOS**

JOÃO VICTOR PÓVOA FRANÇA

Projeto apresentado ao Curso de Sistemas de Informação da Fundação Universidade do Tocantins - UNITINS como parte dos requisitos para a obtenção do grau de Bacharel em Sistemas de Informação, sob a orientação do professor Me. Alex Coelho

PALMAS

2025



UNITINS
UNIVERSIDADE ESTADUAL DO TOCANTINS

TOCANTINS
GOVERNO DO ESTADO



Este trabalho é dedicado à minha família, entes queridos e amigos, pelo carinho,
incentivo e apoio incondicionais.



Agradecimentos

A conclusão deste Trabalho de Conclusão de Curso representa a materialização de um ciclo de aprendizado e dedicação, e não seria possível sem o apoio e a contribuição de diversas fontes.

Em primeiro lugar, a Deus, pela força inabalável, pelo foco concedido nos momentos de maior desafio, pela paciência para superar os obstáculos e pela oportunidade de concretizar este projeto. A fé foi o alicerce que sustentou a jornada, e o que motiva todos os dias a conclusão do curso.

Ao Professor Me. Alex Coelho, meu orientador, pela inestimável contribuição intelectual, pela confiança depositada e pela orientação precisa que guiou o desenvolvimento desta pesquisa, transformando ideias em conhecimento sólido.

Aos meus familiares e entes queridos, pelo amor incondicional, pelo incentivo constante apoio na jornada de trabalho. O apoio de vocês foi fundamental para manter a motivação e a resiliência necessárias.

Por fim, a mim mesmo, pelo esforço e dedicação empregados ao longo de toda a graduação e, em especial, durante a elaboração deste TCC. Este trabalho é o reflexo da persistência e da crença na capacidade de transformar desafios em conquistas.



UNITINS
UNIVERSIDADE ESTADUAL DO TOCANTINS

TOCANTINS
GOVERNO DO ESTADO



“Entrega o teu caminho ao Senhor;
confia nele, e ele tudo fará.” (Bíblia
Sagrada, Salmos 37, 5)



Resumo.....	7
Abstract.....	7
Introdução.....	8
1.1 Objetivos.....	9
1.1.1 Objetivo Geral.....	10
1.1.2 Objetivos Específicos.....	10
2. Referencial Teórico.....	11
2.1. Sistemas de recomendação.....	11
2.1.1 Definição e Histórico.....	12
2.1.2 Casos de Uso em Grandes Empresas.....	14
2.2 Finanças Pessoais.....	16
2.2.1 Desafios Comuns na Gestão Financeira Pessoal.....	16
2.2.2 Psicologia do Consumo e Comportamento Financeiro.....	17
2.3 Inteligência Artificial.....	18
2.3.1 Machine Learning.....	18
2.3.2 Deep Learning.....	19
2.3.3 Agentes Inteligentes.....	20
2.3.4 Exemplos de Aplicação da IA em Finanças.....	21
2.4 Modelos de Filtragem.....	22
3. METODOLOGIA.....	25
3.1 Tipo de Pesquisa e Abordagem.....	25
3.2 Planejamento do Desenvolvimento.....	26
3.3 Desenvolvimento da IA e Integração com o Sistema.....	26
3.4 Tecnologias de Desenvolvimento.....	27
3.4.1 Next.js como adoção de plataforma tecnológica.....	28
3.4.2 TypeScript como suporte de linguagem da plataforma.....	28
4. RESULTADOS.....	29
4.1 Escopo.....	29
4.2 Premissas.....	30
4.3 Requisitos Funcionais.....	30
4.4 Requisitos Não Funcionais.....	32
4.5 Modelagem do Sistema: Diagramas de Casos de Uso, Atividade, Classes e ER.....	33
4.5.1 Atores.....	33
4.5.2 Casos de uso.....	33
4.5.3 Diagramas de Casos de Uso.....	34
4.5.4 Diagramas de Atividade.....	35
4.5.5 Diagrama de Atividade: Geração de Recomendações.....	36
4.5.6 Diagrama de Atividade: Visualizar Explicação Detalhada.....	36



4.5.7 Diagramas de Classe.....	37
4.5.8 Diagrama ER.....	38
4.6 Arquitetura do Sistema.....	40
4.7 CRONOGRAMA.....	41
5. CONSIDERAÇÕES.....	43
REFERÊNCIAS.....	44



Resumo

Este trabalho propõe o desenvolvimento e a validação de um Sistema de Recomendação Financeira Pessoal Inteligente, fundamentado na aplicação de Agentes de Inteligência Artificial (IA), com o propósito primordial de auxiliar indivíduos na mitigação de gastos desnecessários. Em um cenário econômico contemporâneo, caracterizado pela volatilidade e pela crescente complexidade das opções de consumo e crédito, a gestão financeira pessoal tornou-se um desafio premente. Dados recentes do Banco Central do Brasil indicam que uma parcela significativa da população enfrenta dificuldades para manter um controle orçamentário saudável, resultando em altos índices de endividamento e estresse financeiro. A ausência de um planejamento financeiro eficaz e a falta de consciência sobre os padrões de consumo são fatores cruciais que perpetuam essa realidade.

Palavras-chave: finanças; agentes de IA; sistema de recomendação;

Abstract

This work proposes the development and validation of an Intelligent Personal Financial Recommendation System, grounded in the application of Artificial Intelligence (AI) Agents, with the primary purpose of assisting individuals in mitigating unnecessary expenses. In a contemporary economic scenario characterized by volatility and the increasing complexity of consumption and credit options, personal financial management has become a pressing challenge. Recent data from the Central Bank of Brazil indicate that a significant portion of the population faces difficulties in maintaining healthy budget control, resulting in high levels of indebtedness and financial stress. The absence of effective financial planning and the lack of awareness regarding consumption patterns are crucial factors that perpetuate this reality.

Keywords: *personal finance; AI agents; recommender system;*



Introdução

A vida financeira cotidiana exige priorizar despesas e manter um orçamento coerente com metas e renda, mas isso raramente é trivial. O controle depende de acompanhar fluxos, planejar antes de gastar e resistir a compras de baixo valor percebido. Evidências internacionais indicam que muita gente deseja se organizar, mas frequentemente gasta mais do que pretende e tem dificuldade de “ficar dentro do orçamento”. Um Relatório da OCDE avalia que o Letramento financeiro entre adolescentes de 20 economias mundiais demonstrou que o Brasil obteve uma das piores médias de educação financeira entre jovens e adolescentes do mundo.

A definição de educação financeira adaptada para a faixa etária de 15 anos e adotada no Pisa 2022 abrange conhecimento de conceitos financeiros, e habilidades e atitudes para aplicar esse conhecimento, a fim de tomar decisões adequadas em diferentes cenários financeiros. O resultado foi desanimador. O Brasil teve 416 pontos na avaliação de educação financeira, 82 pontos abaixo da média da OCDE (498). No ranking internacional, o Brasil ficou na terceira pior colocação, à frente apenas da Malásia e Arábia Saudita (BANCO CENTRAL DO BRASIL, 2024).

Uma razão estrutural para essa dificuldade é a sobrecarga de escolhas e informações, como em meios de pagamento digitais, ofertas constantes e decisões repetidas no dia a dia aumentam o atrito cognitivo, o que torna mais difícil priorizar o essencial. A literatura psicológica mostra que excesso de opções pode reduzir a ação e a satisfação, em vez de melhorá-las — um efeito documentado em experimentos clássicos sobre escolha, do estudo de Iyengar e Lepper (2000). Assim, além de educação financeira, são úteis ferramentas que organizam o ambiente de decisão e filtram o que importa no momento certo.

É nesse ponto que entram os sistemas de recomendação, tecnologias projetadas para reduzir a sobrecarga informacional e oferecer sugestões personalizadas de alto valor para cada usuário. Em termos conceituais, recomendadores automatizam estratégias de triagem e priorização, ajudando a decidir “o que fazer agora” com base em histórico, preferências e contexto — lógica que pode ser adaptada do consumo



digital para finanças pessoais (priorizar categorias, antecipar riscos de gasto, propor alternativas) (COSTA; AGUIAR; MAGALHÃES, 2013).

De acordo com Costa, Aguiar e Magalhães (2013), a prática de utilizar sistemas de recomendação em contextos educacionais tem se mostrado uma boa estratégia em diferentes cenários, o que reforça a ideia de que abordagens personalizadas podem apoiar decisões — aqui, focadas em controle de despesas.

Com base nisso, este trabalho propõe e avalia um sistema de gestão financeira pessoal, orientado a mitigar gastos desnecessários e a estimular poupança por meio de notificações e alertas oportunos e didáticos. Metodologicamente, caracteriza-se esta pesquisa como aplicada, com etapas de revisão de literatura para embasar as escolhas de modelagem e métricas, prototipação do sistema para uso em ambiente controlado e avaliação empírica com usuários da plataforma. O desenho de avaliação prevê comparação entre condições com e sem intervenção, acompanhando indicadores previamente definidos — por exemplo, variações em despesas discricionárias observadas, aderência a metas e engajamento com as notificações. A análise será conduzida com transparência quanto a limites, suposições e potenciais vieses.

1.1 Objetivos

O presente trabalho tem como objetivo desenvolver uma solução tecnológica voltada à educação e gestão financeira pessoal, utilizando técnicas de Inteligência Artificial aplicadas em sistemas de recomendação. O estudo parte do entendimento de que muitas pessoas têm dificuldade em controlar seus gastos e planejar sua vida financeira, e busca propor uma ferramenta prática e acessível, capaz de oferecer recomendações personalizadas e explicáveis com base no comportamento financeiro real do usuário. Assim, pretende-se contribuir para a construção de hábitos mais conscientes e saudáveis de consumo, abaixo estão objetivos gerais e específicos da ferramenta a ser construída.



1.1.1 Objetivo Geral

Implementar e avaliar um sistema de recomendação financeira pessoal utilizando técnicas de IA para reduzir gastos, estimular poupança, e a educação financeira, entregando notificações e alertas didáticos.

1.1.2 Objetivos Específicos

- Realizar uma revisão bibliográfica abrangente sobre finanças pessoais, inteligência artificial e sistemas de recomendação.
- Analisar os principais desafios enfrentados pelos indivíduos na gestão de suas finanças e na mitigação de gastos supérfluos.
- Projetar a arquitetura de um sistema de recomendação financeira pessoal inteligente, definindo os componentes e as interações entre os agentes de IA.
- Implementar um sistema de recomendação financeira utilizando técnicas de IA.

Este trabalho está organizado em cinco capítulos. O Capítulo 1 apresenta a introdução, os objetivos e a justificativa da pesquisa. O Capítulo 2 traz o referencial teórico, abordando conceitos de inteligência artificial, aprendizado de máquina, mineração de dados e sistemas de recomendação aplicados às finanças pessoais. O Capítulo 3 descreve a metodologia adotada e os requisitos funcionais e não funcionais do sistema. O Capítulo 4 apresenta o desenvolvimento da solução, com os diagramas, arquitetura e resultados obtidos. Por fim, o Capítulo 5 reúne as conclusões, limitações e perspectivas de continuidade do projeto.



2. Referencial Teórico

O presente capítulo reúne os fundamentos conceituais e técnicos que sustentam o desenvolvimento do sistema voltado a apoiar decisões cotidianas de gasto e poupança. Parte-se do reconhecimento de que, no ambiente digital, a abundância de alternativas e informações torna a escolha mais difícil para o usuário comum. Nesse contexto, sistemas de recomendação ganham relevância por priorizarem conteúdos e ações alinhados ao perfil e ao momento de cada pessoa, reduzindo o esforço cognitivo e contribuindo para decisões mais consistentes.

Em síntese, o referencial teórico articula problema, conceitos, modelos e plataforma, oferecendo o alicerce necessário para as decisões de projeto e implementação descritas nos capítulos seguintes. Abaixo aqui apresentado busca tanto conceituar os elementos centrais quanto justificar as escolhas de modelo e de tecnologia adotadas no trabalho.

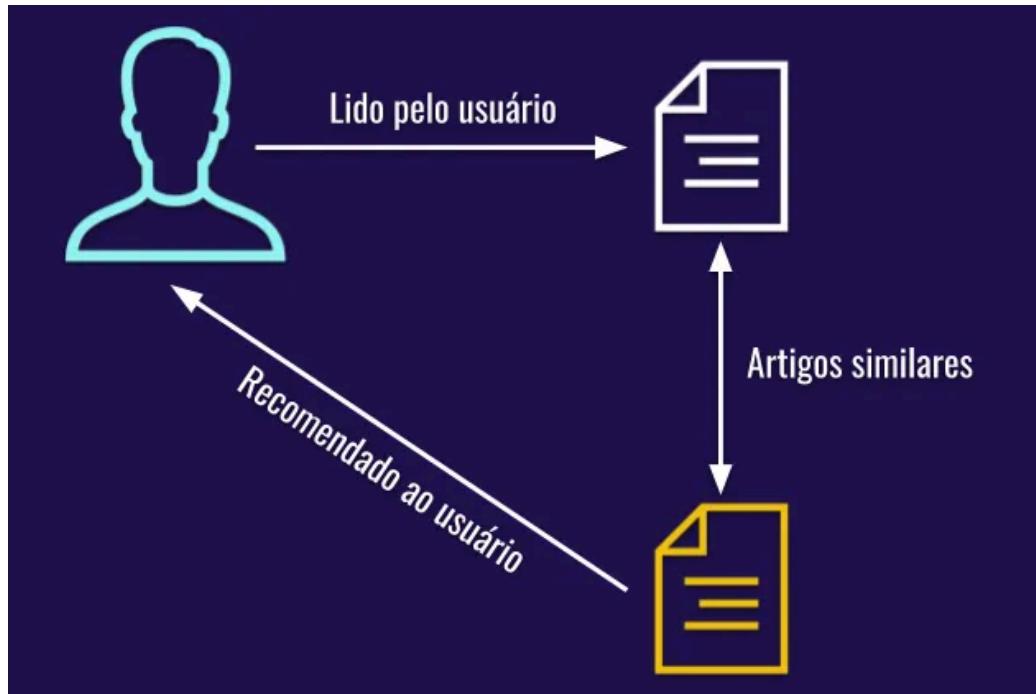
2.1. Sistemas de recomendação

Tomar decisões e fazer escolhas é parte do cotidiano: do momento em que se acorda até a hora de dormir, pessoas compararam alternativas e assumem compromissos que podem gerar satisfação ou frustração. Dispor de um apoio estruturado para selecionar o que é mais adequado ao objetivo imediato tende a reduzir o esforço cognitivo e o risco de arrependimento.

No ambiente digital, porém, a abundância de informações pode dificultar a busca pelo que realmente importa. O bombardeio simultâneo de conteúdos e a falta de familiaridade com o tema pesquisado frequentemente atrapalham o usuário, tornando o processo de seleção mais demorado e menos preciso (FERRO, 2010).

É justamente nesse cenário que surgem os sistemas de recomendação, entendidos como um conjunto de técnicas que, com base em algoritmos e em um histórico de interações, sugerem itens potencialmente relevantes ao usuário (TAKAHASHI; JUNIOR, 2015). Em termos práticos, o recomendador busca reduzir a sobrecarga informacional e priorizar alternativas alinhadas às preferências e ao contexto de cada pessoa, apoiando decisões mais rápidas e consistentes (TAKAHASHI; JUNIOR, 2015; FERRO, 2010).

Figura 1 - Recomendações baseadas em conteúdo.



Fonte: SOUZA, Evandro F. *Sistemas de recomendação*. Medium.

Essa imagem representa a base de um sistema de recomendação e como esses dados são guardados e trafegados, a partir de uma cruz de dados em que o usuário que está buscando essa recomendação pede, e assim é feito a também com dados já obtidos pelo próprio sistema desse usuário, e assim tendo o aprendizado do modelo de inteligência artificial.

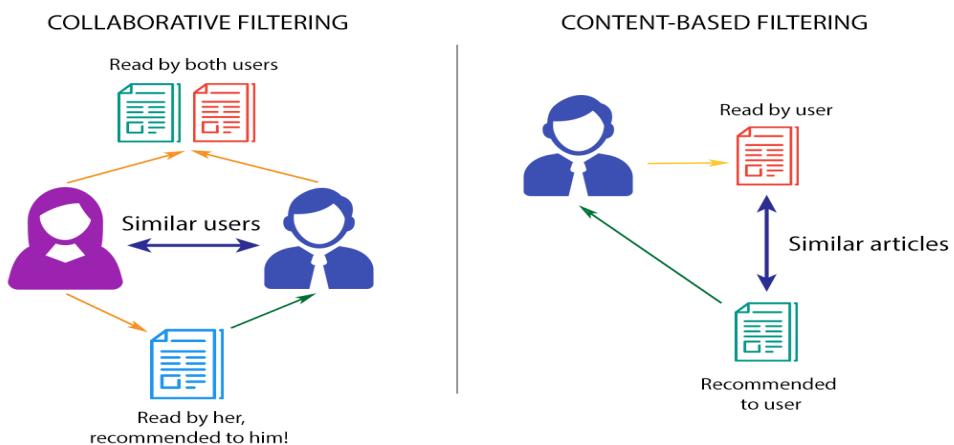
2.1.1 Definição e Histórico

De forma conceitual, os sistemas de recomendação são ferramentas tecnológicas que sugerem itens ou ações personalizadas com base em preferências, histórico e comportamento dos usuários. Resnick e Varian (1997) apontam que sua origem remete aos anos 1990, com sistemas pioneiros como GroupLens e Tapestry, que introduziram a noção de “filtragem colaborativa” como método para filtrar informações por meio da colaboração entre usuários (REATEGUI; CAZELLA, 2005). Desde então, essas técnicas se expandiram, incorporando abordagens de mineração de dados e inteligência artificial, consolidando-se em aplicações que vão de e-commerce até educação e entretenimento digital.

O histórico da área remonta ao início da década de 1990, com experimentos pioneiros como o *Tapestry*, proposto por Goldberg et al. (1992), considerado o primeiro sistema de filtragem colaborativa, no qual os usuários compartilhavam manualmente suas opiniões para ajudar outros na filtragem de mensagens de e-mail. Logo depois, Konstan et al. (1997) apresentaram o *GroupLens*, que introduziu a filtragem colaborativa automatizada em grupos de discussão da Usenet, constituindo o embrião dos sistemas de recomendação modernos. Reategui e Cazella (2005) observam que esses primeiros autores utilizaram a expressão *filtragem colaborativa* justamente para enfatizar a interferência social e a troca de informações entre usuários como forma de refinar recomendações.

Com a evolução da área, pesquisadores passaram a integrar novas técnicas oriundas da mineração de dados e da inteligência artificial. Linden, Smith e York (2003) destacam que a popularização dos sistemas de recomendação ocorreu em grande escala com a Amazon, cujo algoritmo “item-to-item collaborative filtering” tornou-se referência prática por priorizar a comparação entre itens em vez de usuários, sendo altamente escalável para catálogos extensos. De acordo com os autores, esse modelo “procura itens semelhantes, não clientes semelhantes” (LINDEN; SMITH; YORK, 2003, p. 78), garantindo recomendações em tempo real com menor custo computacional.

Figura 2 - Filtragem colaborativa a partir de usuário versus a partir de itens gerando recomendação.



Fonte: DI FANTE, Artur Lunardi. *Collaborative-based recommendation system using SVD. Medium.*



Atualmente, a literatura enfatiza que os sistemas de recomendação não se restringem mais a ambientes de e-commerce ou entretenimento. Segundo Zibriczky (2016), sua aplicação tem se expandido para domínios mais complexos, como serviços financeiros, onde a personalização deve lidar com múltiplos critérios, riscos e a necessidade de explicabilidade. Isso demonstra que, embora tenham surgido como soluções de filtragem de informação, esses sistemas se tornaram ferramentas críticas para apoiar decisões em áreas sensíveis e de alto impacto, como a vida financeira pessoal.

2.1.2 Casos de Uso em Grandes Empresas

A difusão dos sistemas de recomendação ocorreu principalmente em setores como e-commerce e streaming, com empresas como Amazon, Google e Netflix utilizando recomendações como estratégia competitiva para personalizar a experiência do usuário e aumentar a adesão a produtos e serviços (TAKAHASHI; JUNIOR, 2015; ACOSTA, 2016). Mais recentemente, marketplaces como Shopee também passaram a aplicar técnicas baseadas em histórico de compras e favoritos (MOURA, 2023). Esses exemplos ilustram como o mecanismo de recomendação atua em contextos de consumo, podendo ser adaptado para a gestão de finanças pessoais, auxiliando o usuário a identificar padrões de gastos e oportunidades de economia.

Em finanças, mapeia-se aplicações que vão de recomendação de produtos bancários e seguros a carteiras e ações; tais domínios trazem requisitos específicos (multiobjetivos, sensibilidade temporal, necessidade de explicação) que diferenciam finanças de outros cenários. Em bancos e cartões, há evidência de recomendação baseada em hábitos de gasto (transações de cartão) para campanhas personalizadas usando fatoração de matriz (ALS) em larga escala (MOURA, 2023).

No setor financeiro, a literatura acadêmica aponta aplicações específicas que combinam dados transacionais e contexto. Em protótipos de bancos, recomendações “baseadas no histórico de uso do cartão de crédito e dados de geolocalização [...] fornecem recomendações personalizadas sobre oportunidades de gasto próximas ao usuário”. Ao mesmo tempo, os autores destacam a relevância da privacidade e a consequente necessidade de aplicabilidade por se tratar de decisões de dinheiro — domínios de “alto risco” com “demanda significativa por explicação” (MOURA, 2023).

Há, ainda, casos de uso orientados a crédito e microfinanças. Em plataformas P2P como a Kiva, estudos investigam emparelhamentos entre credores e tomadores — por exemplo, métodos de máxima entropia e abordagens de filtragem colaborativa para buscar um “pareamento justo” de empréstimos conforme o perfil e o risco. Esses trabalhos mostram como técnicas de recomendação podem apoiar tanto a eficiência operacional quanto critérios de equidade nesse domínio sensível (TAKAHASHI; JUNIOR, 2015; ACOSTA, 2016).

Seguros e aconselhamento financeiro também figuram como alvos frequentes. Há protótipos web em tempo real que recomendam apólices e “riders” (coberturas adicionais) e, em cenários multi-critérios, recomendações baseadas em conhecimento são preferidas por representarem melhor restrições e objetivos financeiros — “aplicam-se mais eficientemente em decisões financeiras baseadas em múltiplos critérios”. Esse enfoque reforça a importância de transparência e controle pelo usuário em decisões de alto impacto (TAKAHASHI; JUNIOR, 2015; ACOSTA, 2016).

Tabela 1 – Áreas de aplicação dos sistemas de recomendação

Domínio de aplicação	Exemplos de empresas	Descrição (exemplos de uso)
E-commerce e Varejo	Amazon, Shopee	Mostrar produtos semelhantes; sugerir itens com base em palavras-chave pesquisadas; adicionar ao carrinho.
Entretenimento e Mídia	Netflix	Ajudar a criar playlists; sugerir filmes, séries ou músicas personalizadas.
Redes Sociais	Instagram, Facebook	Oferecer sugestões de conexões (“pessoas que você talvez conheça”); indicar grupos ou páginas relevantes.
Plataformas de Busca de Conteúdo	YouTube, Google	Recomendar materiais ou artigos com base no histórico de navegação do usuário.
Educação	G2 educação	Sugerir cursos, trilhas de aprendizagem ou materiais de estudo de acordo com o usuário.
Serviços Financeiros e	Kiva (P2P lending)	Fornecer conselhos financeiros personalizados; recomendar produtos



Bancários		financeiros como cartões, seguros ou investimentos.
-----------	--	---

Fonte: Adaptado da imagem *Applications of recommender systems in different domains* (2023).

A tabela anterior apresenta um panorama dos principais domínios de aplicação dos sistemas de recomendação em grandes empresas e setores variados. O objetivo é demonstrar como essa tecnologia se tornou essencial para personalizar experiências, aumentar o engajamento do usuário e apoiar decisões automatizadas em diferentes contextos. Observa-se que, embora os primeiros avanços tenham ocorrido em áreas como e-commerce e entretenimento, as recomendações hoje se estendem para setores mais complexos, como educação e serviços financeiros, cada um com suas particularidades e desafios.

2.2 Finanças Pessoais

As finanças pessoais constituem um campo de estudo e prática que se refere à gestão dos recursos monetários de um indivíduo ou de uma família, englobando um conjunto de atividades como planejamento, orçamento, poupança, investimento, gestão de dívidas e proteção financeira. O objetivo primordial dessa gestão é assegurar a estabilidade econômica, promover a segurança financeira e viabilizar a concretização de metas de curto, médio e longo prazo, tais como a aquisição de bens duráveis, a formação de um patrimônio, a preparação para a aposentadoria ou o financiamento da educação(TAKAHASHI; JUNIOR, 2015; ACOSTA, 2016).

A complexidade inerente a essa área, aliada à falta de conhecimento específico e de disciplina, pode culminar em sérios problemas financeiros, como o endividamento excessivo, a inadimplência e o consequente estresse financeiro, que afeta não apenas a saúde econômica, mas também o bem-estar psicológico dos indivíduos.

2.2.1 Desafios Comuns na Gestão Financeira Pessoal

Apesar da importância do planejamento financeiro, muitos indivíduos enfrentam obstáculos significativos em sua organização econômica. Estudos



nacionais e internacionais indicam que a baixa literacia financeira compromete a tomada de decisão e aumenta a exposição a comportamentos de risco, dificultando o controle do orçamento e favorecendo o endividamento (BANCO CENTRAL DO BRASIL, 2024; OECD, 2024). Entre os desafios mais prevalentes, destacam-se:

- **Consumismo e Compras por Impulso:** A sociedade moderna, impulsionada por estratégias de marketing agressivas e pela facilidade de acesso ao crédito, frequentemente estimula o consumo excessivo e as compras por impulso — um comportamento associado à baixa literacia financeira e decisões irrationais de consumo (OECD, 2024; BANCO CENTRAL DO BRASIL, 2024).
- **Falta de Disciplina e Planejamento:** A ausência de orçamento, o monitoramento inadequado das despesas e a dificuldade em manter hábitos financeiros saudáveis são apontados pela OCDE como fatores centrais para o descontrole financeiro (OECD, 2024).
- **Acesso Fácil ao Crédito e Juros Elevados:** O acesso amplo ao crédito, quando associado à baixa compreensão sobre juros e riscos, aumenta substancialmente o endividamento das famílias, especialmente em países com taxas elevadas, como o Brasil (BANCO CENTRAL DO BRASIL, 2024).
- **Inflação e Cenário Econômico Volátil:** A OCDE destaca que condições macroeconômicas instáveis — como inflação e queda do poder de compra — afetam diretamente a capacidade de planejamento financeiro e intensificam comportamentos de curto prazo (OECD, 2024).

2.2.2 Psicologia do Consumo e Comportamento Financeiro

Compreender as finanças pessoais vai além dos números; envolve também a psicologia do consumo. Decisões financeiras são frequentemente influenciadas por fatores emocionais, sociais e cognitivos. O desejo de status social, a necessidade de



pertencimento, a busca por gratificação instantânea e a aversão à perda são alguns dos vieses comportamentais que podem levar a gastos desnecessários e a decisões financeiras erradas. A educação financeira, nesse contexto, não se limita a ensinar sobre produtos financeiros, mas também a desenvolver a inteligência emocional e a autoconsciência para resistir a impulsos e tomar decisões alinhadas aos objetivos de longo prazo, conforme apontam estudos que relacionam comportamentos emocionais, cognitivos e sociais à tomada de decisão financeira (IYENGAR; LEPPER, 2000; OECD, 2024; BANCO CENTRAL DO BRASIL, 2024).

2.3 Inteligência Artificial

A Inteligência Artificial (IA) constitui um campo da ciência da computação voltado ao desenvolvimento de sistemas capazes de reproduzir aspectos da cognição humana, realizando tarefas como aprendizado, raciocínio, percepção, resolução de problemas e tomada de decisão. Desde suas primeiras abordagens fundamentadas em regras e programação explícita, a área evoluiu para métodos mais sofisticados baseados em aprendizado de máquina, nos quais algoritmos extraem padrões a partir de grandes volumes de dados, reduzindo a necessidade de instruções determinísticas (TAKAHASHI; JUNIOR, 2015; COSTA; AGUIAR; MAGALHÃES, 2013).

No contexto deste trabalho, a IA desempenha um papel essencial na identificação de padrões de comportamento financeiro e na geração de recomendações personalizadas para auxiliar indivíduos na redução de gastos desnecessários. A literatura destaca que técnicas modernas de IA, especialmente aquelas aplicadas em sistemas de recomendação, permitem compreender preferências e hábitos de usuários de forma dinâmica e contextualizada, aumentando a precisão das sugestões oferecidas (ZHANG; CHEN, 2020). Assim, compreender os principais paradigmas e métodos de IA torna-se fundamental para a implementação do sistema proposto.

2.3.1 Machine Learning

Machine Learning (Aprendizado de Máquina) representa o fundamento técnico que possibilita que sistemas computacionais aprendam a partir de dados e identifiquem padrões complexos de comportamento. Em aplicações financeiras, esses algoritmos



permitem analisar volumes extensos de transações, categorizar automaticamente despesas, prever padrões de consumo e detectar anomalias associadas a gastos atípicos. Métodos amplamente utilizados nesse contexto incluem modelos de regressão, algoritmos de classificação, árvores de decisão, SVM e redes neurais — técnicas também presentes em sistemas de recomendação e análise sequencial, que se beneficiam do reconhecimento de padrões e da extração de relações entre itens ou comportamentos de usuários (SARWAR et al., 2001; LINDEN; SMITH; YORK, 2003; QUADRANA; CREMONESI; JANNACH, 2018; ZIBRICZKY, 2016).

2.3.2 Deep Learning

Deep Learning (Aprendizado Profundo) constitui uma subárea do *Machine Learning* baseada no uso de redes neurais artificiais profundas, capazes de aprender representações hierárquicas e altamente complexas dos dados. Segundo Goodfellow, Bengio e Courville (2016), redes profundas conseguem extrair automaticamente padrões em níveis crescentes de abstração, superando limitações de modelos tradicionais ao lidar com dados complexos e não estruturados. No contexto deste estudo, essa capacidade mostra-se essencial para analisar informações financeiras que vão além de valores numéricos, permitindo interpretar descrições textuais de transações, detectar padrões ocultos em séries temporais de gastos e identificar comportamentos de consumo que não seriam captados por técnicas de aprendizado mais superficiais.

Ainda conforme Goodfellow, Bengio e Courville (2016), arquiteturas profundas como LSTMs e redes convolucionais são particularmente eficazes em tarefas que envolvem sequências e variações temporais — o que se alinha diretamente às necessidades deste trabalho, que envolve a análise contínua das despesas do usuário ao longo do tempo. Dessa forma, o *Deep Learning* contribui para a identificação de tendências, sazonalidades e possíveis irregularidades financeiras com maior precisão e adaptabilidade.

2.3.3 Agentes Inteligentes

Um agente inteligente é definido por Russell e Norvig (2022) como uma entidade autônoma capaz de perceber o ambiente por meio de sensores e agir sobre ele

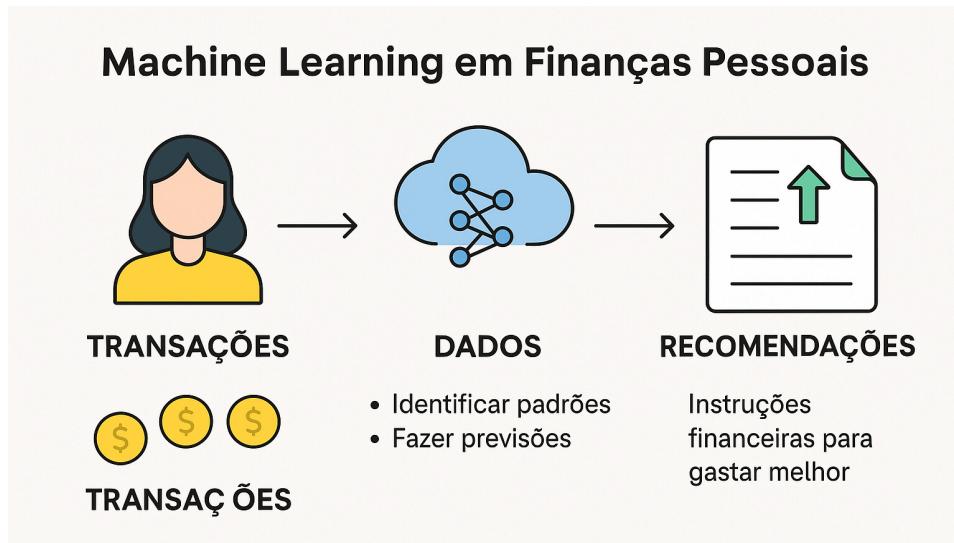


através de atuadores, buscando alcançar metas específicas. Segundo os autores, esses agentes distinguem-se por quatro propriedades fundamentais: autonomia, que lhes permite operar sem intervenção constante; reatividade, pela capacidade de responder a mudanças no ambiente; proatividade, ao perseguirem objetivos de maneira deliberada; e sociabilidade, ao interagirem com outros agentes ou com seres humanos. No contexto deste estudo, tais características são essenciais para que o sistema execute suas funções de forma contínua, adaptativa e orientada a metas — especialmente em aplicações que envolvem análise financeira dinâmica e recomendações personalizadas.

Russell e Norvig (2022) também destacam que agentes podem ser projetados com diferentes arquiteturas, desde agentes simples baseados em regras até agentes baseados em aprendizado, que empregam técnicas de Machine Learning e Deep Learning. Nesta pesquisa, o sistema de recomendação financeira utiliza precisamente essa abordagem de agentes baseados em aprendizado, que operam de forma contínua, aprendem com o comportamento do usuário e ajustam suas ações automaticamente conforme novos dados são incorporados.

- Monitorar Transações: Um agente pode ser responsável por coletar e categorizar automaticamente as transações financeiras do usuário, identificando padrões de gastos.
- Identificar Gastos Desnecessários: Outro agente pode analisar os padrões identificados, compará-los com orçamentos predefinidos ou com o comportamento de grupos de usuários semelhantes, e sinalizar despesas que se enquadram como supérfluas.
- Gerar Recomendações: Um agente de recomendação, utilizando algoritmos de Machine Learning, pode sugerir ações específicas para mitigar esses gastos, como sugerir alternativas mais econômicas, alertar sobre gastos recorrentes excessivos ou propor metas de economia.
- Interagir com o Usuário: Agentes podem se comunicar com o usuário através de interfaces amigáveis, explicando as recomendações e coletando feedback para refinar suas sugestões.

Figura 4 - A explicação base de agentes inteligentes com ML para a recomendação financeira



Fonte: Elaborada pelo autor (2025)

2.3.4 Exemplos de Aplicação da IA em Finanças

A Inteligência Artificial já está amplamente incorporada ao setor financeiro, atuando desde a automação operacional até a oferta de serviços altamente personalizados. Russell e Norvig (2022) destacam que sistemas inteligentes são particularmente eficientes em ambientes que exigem análise contínua de dados, tomada de decisão dinâmica e adaptação a novos comportamentos — características que tornam a IA ideal para aplicações financeiras contemporâneas. Algumas das áreas como:

- Detecção de Fraudes: Algoritmos de IA analisam padrões de transações para identificar atividades suspeitas e prevenir fraudes em tempo real.
- Chatbots e Assistentes Virtuais: Utilizados por bancos e instituições financeiras para atendimento ao cliente, respondendo a perguntas, auxiliando em transações e fornecendo informações financeiras básicas.
- Análise de Mercado e Previsão: Modelos de IA analisam dados de mercado para prever tendências, otimizar portfólios de investimento e auxiliar na tomada de decisões estratégicas.
- Personalização de Serviços Financeiros: Bancos e fintechs utilizam IA para oferecer produtos e serviços financeiros personalizados, como linhas de crédito



pré-aprovadas, seguros adaptados ao perfil do cliente ou recomendações de investimento baseadas no apetite a risco individual.

- **Otimização de Custos Operacionais:** A IA generativa e outras técnicas de IA são empregadas para automatizar tarefas repetitivas, otimizar a alocação de recursos e identificar ineficiências, resultando em significativa redução de custos para as empresas

Em resumo, a Inteligência Artificial oferece um vasto leque de possibilidades para transformar a gestão financeira pessoal, tornando-a mais inteligente, proativa e alinhada aos objetivos individuais. A integração de agentes de IA em sistemas de recomendação é um passo natural para alavancar essas capacidades em benefício do usuário final.

2.4 Modelos de Filtragem

Na filtragem colaborativa, o sistema aprende padrões de comportamento entre usuários e itens para predizer interesse. Técnicas *item-based* escalam bem e analisam relações entre itens na matriz usuário–item (SARWAR et al., 2001). O algoritmo “item-to-item” da Amazon ficou conhecido por “procurar itens semelhantes, não clientes semelhantes” (tradução nossa), agregando similares aos itens do usuário para recomendar em tempo real (LINDEN; SMITH; YORK, 2003).

Em domínios com feedback implícito (cliques, compras, transações), a fatoração de matrizes e objetivos de ranqueamento (como BPR) tornaram-se padrão, pois capturam preferências sem depender de avaliações explícitas (KOREN; BELL; VOLINSKY, 2009; RENDLE et al., 2009). Para finanças pessoais, isso é particularmente pertinente: registros de transação funcionam como sinais implícitos, permitindo aprender o que reduzir/priorizar a partir de comportamentos de perfis semelhantes.

Esses modelos sustentam grande parte das aplicações atuais e podem ser estendidos ao contexto de recomendações financeiras, onde o desafio não é apenas indicar novos produtos, mas alertar para gastos desnecessários e sugerir alternativas de poupança com base no perfil e nas escolhas anteriores do usuário.

Os modelos híbridos combinam vantagens das abordagens anteriores e são recomendados quando há sparsity, frio de arranque e necessidade de robustez — cenário



comum em uso financeiro (BURKE, 2002). Podem misturar escores (ponderação), alternar conforme contexto, enriquecer o colaborativo com atributos de conteúdo (feature-aware) e incluir camadas baseadas em conhecimento (regras/constraints). Revisões específicas do setor mapeiam o uso de híbridos em bancos, seguros e investimentos, destacando requisitos de multiobjetivo (poupança vs. conveniência), sensibilidade temporal e explicabilidade (ZIBRICZKY, 2016; SHARAF et al., 2022).

Para o FinancePro, isso se traduz em unir: (i) sinais transacionais (categoria, frequência, horário), (ii) evidências de pares (o que funcionou para perfis semelhantes) e (iii) regras de negócio e limites (p. ex., categorias essenciais), produzindo recomendações explicáveis.

Por fim, estudos aplicados em bancos mostram que hábitos de gasto extraídos de cartões podem orientar campanhas e ações personalizadas (ALS, CF) em produção. Esses achados sustentam o desenho de um híbrido explicável para o FinancePro: conteúdo para clareza e rastreabilidade; colaborativo/model-based (MF/BPR/NCF) para priorizar ações de economia que funcionam para perfis similares; e sequência/tempo para acertar o momento do alerta — reforçando o papel dos modelos de filtragem como base técnica para mitigar gastos desnecessários (KAYA; GEZER; GÜLSEÇEN, 2021).

Tabela 2 - Modelos de filtragem em sistemas de recomendação.

Modelo	Ideia central	Vantagem	Limitação	Fonte
Colaborativa (User-based)	Usuários com gostos semelhantes recebem itens parecidos.	Intuitiva, fácil de aplicar.	Problema de escalabilidade.	SARWAR et al. (2001)
Colaborativa (Item-to-item)	Itens semelhantes entre si são recomendados.	Escalável, baixo custo.	Pode ignorar mudanças rápidas.	LINDEN; SMITH; YORK (2003)
Fatoração de Matrizes (MF, BPR)	Descobre padrões latentes em dados de interação.	Funciona bem com feedback implícito.	Difícil de interpretar.	KOREN; BELL; VOLINSKY (2009); RENDLE et al.



				(2009)
Híbrida	Combina colaborativa, conteúdo e regras.	Mais robusta e explicável.	Complexidade.	BURKE (2002); ZIBRICZKY (2016); SHARAF et al. (2022)

Fonte: Adaptado de Sarwar et al. (2001); Linden, Smith e York (2003); Koren, Bell e Volinsky (2009); Rendle et al. (2009); Burke (2002); Zibruczky (2016); Sharaf et al. (2022).

Nesta tabela está resumido os principais modelos de filtragem utilizados em sistemas de recomendação, destacando suas ideias centrais, vantagens e limitações. Cada abordagem evoluiu para atender diferentes contextos e necessidades de personalização, desde os modelos colaborativos tradicionais até as soluções híbridas mais recentes. Enquanto os métodos baseados em usuários e itens foram fundamentais nas primeiras gerações de sistemas, proporcionando recomendações intuitivas e rápidas, técnicas como a fatoração de matrizes e o aprendizado por ranqueamento trouxeram maior precisão e capacidade de lidar com grandes volumes de dados. Os modelos híbridos, por sua vez, representam uma evolução importante por combinarem o melhor de cada abordagem, equilibrando desempenho, interpretabilidade e aplicabilidade prática. No contexto do trabalho, compreender essas variações é essencial, pois a escolha adequada do modelo impacta diretamente na qualidade das recomendações e na confiança do usuário nas sugestões geradas.

3. METODOLOGIA

A metodologia adotada para o desenvolvimento do Sistema de Recomendação Financeira Pessoal Inteligente seguiu uma abordagem híbrida, com elementos de pesquisa aplicada e desenvolvimento ágil, buscando aliar teoria e prática para criar uma solução robusta e escalável. A metodologia foi dividida em três etapas principais: definição do problema, projeto do sistema e implementação e avaliação. Cada uma



dessas etapas contribuiu para garantir que o sistema atendesse às necessidades dos usuários e fosse capaz de oferecer recomendações personalizadas e explicáveis.

3.1 Tipo de Pesquisa e Abordagem

A pesquisa é caracterizada como aplicada, pois visa resolver um problema específico relacionado à gestão financeira pessoal, por meio da aplicação de sistemas de recomendação baseados em Inteligência Artificial (IA). Para isso, foi adotada uma abordagem qualitativa, focada em entender as necessidades dos usuários e como essas necessidades poderiam ser atendidas através de uma solução tecnológica eficiente. Inicialmente, o projeto foi planejado com base em análises das dificuldades comuns enfrentadas pelos usuários em relação ao controle financeiro pessoal. A partir dessa análise, foi possível identificar as áreas em que um sistema de recomendação inteligente poderia ter um impacto significativo, como a mitigação de gastos desnecessários e o auxílio no planejamento financeiro. O objetivo principal é ajudar os usuários a mitigar gastos desnecessários e promover hábitos de economia, utilizando algoritmos de IA para personalizar as recomendações com base em seu histórico financeiro.

De acordo com Costa, Aguiar e Magalhães (2013), sistemas de recomendação adaptados ao comportamento do usuário, como no caso do *projeto*, ajudam a reduzir a sobrecarga informacional e apoiar decisões financeiras, filtrando apenas as informações relevantes. Zibriczky (2016) também afirma que a personalização de recomendações em domínios financeiros exige um manejo cuidadoso de múltiplos critérios e variáveis, como risco e aplicabilidade das recomendações.

Além disso, a pesquisa será orientada para a inovação tecnológica em um cenário de alto impacto social, dado o crescimento de endividamento da população e a complexidade dos serviços financeiros disponíveis. O trabalho seguirá uma abordagem iterativa, permitindo ajustes contínuos conforme o sistema de recomendação evolui e interage com os usuários, com a finalidade de gerar resultados mais precisos e eficazes ao longo do tempo.



3.2 Planejamento do Desenvolvimento

O desenvolvimento do Sistema de Recomendação Financeira Pessoal Inteligente será dividido em várias fases, com o objetivo de garantir que cada etapa seja validada antes de avançar para a próxima. A primeira fase consistirá no planejamento do sistema, onde as tecnologias e metodologias a serem utilizadas serão definidas. Para isso, foi realizada uma análise de requisitos técnicos e funcionais, levando em consideração as necessidades dos usuários e a integração com os algoritmos e modelos de recomendação com IA.

A segunda fase será voltada para o desenvolvimento da arquitetura do sistema e a definição do modelo de Inteligência Artificial a ser utilizado. O sistema adotará uma arquitetura modular e escalável, em que o *backend* será construído com Node.js e Nest.js para garantir alta performance e flexibilidade. O modelo de IA será desenvolvido utilizando técnicas de Machine Learning (ML) e Reinforcement Learning, permitindo que o sistema aprenda com os dados financeiros dos usuários e forneça recomendações personalizadas baseadas em seus padrões de consumo.

Por fim, a terceira fase envolverá a integração do sistema com o frontend, utilizando Next.js para garantir uma interface responsiva e fácil de usar. O sistema será projetado para fornecer feedback em tempo real sobre as finanças dos usuários, com a geração de recomendações personalizadas para cada um. O processo será altamente iterativo, com ciclos curtos de feedback e ajustes durante o desenvolvimento.

3.3 Desenvolvimento da IA e Integração com o Sistema

A parte central do Sistema de Recomendação será o motor de IA, responsável por analisar os dados de transações financeiras e gerar recomendações. A escolha do modelo de IA será fundamental para garantir a personalização das sugestões, de acordo com o comportamento de consumo de cada usuário. O modelo de IA utilizará técnicas de filtragem colaborativa, como *Item-to-Item Collaborative Filtering*, e algoritmos de aprendizado por reforço para adaptar as recomendações com base nas interações dos usuários com o sistema.



Além disso, será integrado ao sistema uma arquitetura baseada em *webhooks* para receber dados de transações bancárias e realizar atualizações em tempo real, permitindo que o sistema de recomendações forneça sugestões instantâneas, com base em dados mais recentes. Essa integração será feita utilizando *APIs RESTful e JSON*, como recomendado por Fielding (2000) para garantir comunicação eficiente e escalável entre as camadas do sistema.

A fase de avaliação do modelo de IA será baseada em simulações de dados financeiros e em testes de validação cruzada para garantir que as recomendações fornecidas sejam precisas e relevantes. A utilização de feedback contínuo dos usuários, ainda que em testes simulados, permitirá que os algoritmos sejam ajustados e otimizados para oferecer uma experiência personalizada, levando em conta os padrões de consumo e as metas financeiras de cada indivíduo. Como afirmado por Resnick e Varian (1997), o feedback do usuário é essencial para a melhoria contínua dos sistemas de recomendação, permitindo ajustes dinâmicos e a personalização de longo prazo.

3.4 Tecnologias de Desenvolvimento

A operacionalização dos modelos de recomendação descritos nas seções anteriores exige uma base tecnológica que entregue atualidade de dados, baixa latência e manutenibilidade. A escolha da plataforma de desenvolvimento em Next.js, adotará um framework que combina renderização no servidor e pré-renderização, suportando interfaces personalizadas (painéis por usuário) e páginas informativas estáveis (ajuda, termos) com bom desempenho.

A opção pelo *Next.js* atende a esses pontos porque o framework combina diferentes formas de preparação das páginas (no servidor e antecipadas), prática recomendada na engenharia web para melhorar a experiência inicial e a indexação quando for pertinente. Em termos gerais, enviar HTML pronto e reduzir o JavaScript executado no navegador costuma diminuir a espera do usuário e tornar a navegação mais estável — algo especialmente importante em telas de finanças pessoais com gráficos e textos explicativos.



3.4.1 Next.js como adoção de plataforma tecnológica

De forma simples, o *Next.js* permite escolher como cada página será gerada, conforme a necessidade do projeto:

- Quando o conteúdo precisa refletir o estado atual do usuário (painel, alertas, metas), a página pode ser montada a cada acesso no servidor (SSR);
- Quando o conteúdo é mais estável (ajuda, termos, landing), a página pode ser pré-gerada em tempo de build e servida muito rápido (SSG);
- Quando é dinâmico (listas e relatórios que mudam periodicamente), a página pode ser pré-gerada e revalidada automaticamente em intervalos configurados (ISR). Essa flexibilidade ajuda a equilibrar frescor da informação e custo de operação na prática.

Para conectar a camada web aos módulos de IA e aos serviços de dados, o *Next.js* oferece *API Routes* e *Route Handlers*, isto é, *endpoints HTTP* dentro do próprio projeto, empacotados apenas no servidor. É “*the solution to build a public API with Next.js*”, útil no MVP para autenticação, *webhooks* de revalidação (ISR) e entrega de recomendações, com possibilidade de evoluir a um backend dedicado quando necessário.

3.4.2 TypeScript como suporte de linguagem da plataforma

Por fim, o suporte nativo a *TypeScript* acrescenta tipagem estática ao projeto, reduzindo ambiguidades em contratos de API, esquemas de dados financeiros e regras de recomendação. Como resume a documentação oficial, o *TypeScript* “*highlight[s] unexpected behavior [...] lowering the chance of bugs*”, ou seja, a diminuição de aspectos inesperados, ou como a linguagem técnica entende, *bugs*, aspecto crucial em domínios sensíveis como finanças pessoais.

Em síntese, a adoção do *Next.js* no projeto alinha a camada de apresentação ao propósito do sistema de recomendação: páginas personalizadas e atualizadas quando necessário (SSR), conteúdo estável e veloz quando possível (SSG/ISR), menor carga de JS no cliente (*Server Components*), integração *full-stack* via rotas de API e otimizações



de UX integradas — todos pontos sustentados pela literatura técnica recente para a documentação da própria ferramenta.

4. RESULTADOS

Nesta seção, serão apresentados os resultados obtidos com o desenvolvimento do Sistema de Recomendação Financeira Pessoal Inteligente, destacando a arquitetura da solução, os requisitos atendidos, os diagramas que representam a interação do sistema com os usuários, bem como a implementação dos componentes principais. O objetivo é demonstrar como o sistema foi projetado, testado e validado para alcançar a eficácia esperada, com foco na otimização do orçamento e na redução de gastos desnecessários. A partir das funcionalidades implementadas, será possível observar como a aplicação de técnicas de inteligência artificial pode melhorar a gestão financeira pessoal.

O processo de desenvolvimento foi fundamentado em uma abordagem estruturada e iterativa, visando garantir que as funcionalidades propostas fossem não apenas eficazes, mas também explicáveis e compreensíveis para os usuários. A seção a seguir irá detalhar como cada componente do sistema foi projetado e implementado, explicando os testes realizados e os resultados alcançados. Com isso, o objetivo é fornecer uma visão clara sobre o funcionamento da solução e a sua aplicação prática para promover uma gestão financeira mais eficiente e inteligente para os usuários.

4.1 Escopo

O projeto proposto consistirá em uma plataforma web voltada para apoiar as pessoas no controle de suas finanças pessoais. A aplicação receberá transações do usuário e organiza esses dados em categorias e relatórios, dando ao usuário uma visão geral de seus gastos e receitas.

A proposta é organizar transações financeiras, gera relatórios e permitir visualizações de gastos por categoria, além de oferecer ações propositivas para orientar o usuário em como gastar melhor.

Este trabalho propõe a criação de um módulo de recomendações explicáveis, que será integrado ao sistema de gestão. Assim, o objetivo será identificar padrões de



consumo a partir das transações e gerar sugestões personalizadas para ajudar o usuário a economizar e melhorar suas escolhas financeiras. O diferencial é que cada recomendação será acompanhada de uma explicação simples e clara, permitindo que o usuário entenda os motivos por trás da sugestão e, assim, confie mais no sistema e possa assim melhorar a sua gestão de finanças pessoais ainda mais.

A proposta neste trabalho traz um módulo de recomendações que terá as seguintes funções principais:

- Analisar as transações do usuário e identificar padrões de gastos.
- Gerar recomendações personalizadas com impacto estimado (por exemplo: “economia de R\$ 100/mês se reduzir pedidos de delivery em 20%”).
- Apresentar cada recomendação com explicações curtas e claras, facilitando a compreensão.

Em resumo, o escopo do projeto consiste em um sistema que não apenas mostra os dados para uma plataforma mas que também orienta o usuário, oferecendo recomendações simples, contextualizadas e úteis para apoiar suas decisões financeiras.

Dessa forma, a proposta não se prende apenas a um sistema de organização e visualização de dados mas que também gera apoio direto na tomada de decisões, auxiliando o usuário em situações comuns como falta de planejamento, gastos por impulso e risco de endividamento.

4.2 Premissas

- O usuário acessará o sistema principalmente via navegador web (desktop e mobile).
- O módulo de recomendação funcionará em cima da base de dados de transações de cada usuário já existente.

4.3 Requisitos Funcionais

A funcionalidade de recomendação no trabalho inicia-se com a mineração e análise de dados das transações que o usuário já possui no sistema. A partir desses registros, o módulo de IA extrai informações relevantes, aprende padrões de consumo e,



então, gera recomendações explicáveis para apoiar decisões de economia. O processo ocorre em etapas, e para isso, construímos os requisitos funcionais deste módulo.

Tabela 3 - Requisitos Funcionais do Projeto

ID	Requisito	Descrição / Critérios de Aceite
RF01	Coletar e unificar transações do usuário	O sistema deve usar apenas as transações já existentes (data, descrição, valor, categoria).
RF02	Realizar limpeza e padronização de dados	Datas, valores e descrições devem estar normalizados; duplicatas removidas; exemplos como “IFOOD*123” → “Delivery”.
RF03	Extrair atributos relevantes	O sistema deve calcular frequência, sazonalidade, tendência e recorrência.
RF04	Modelar padrões de consumo	O módulo de IA deve identificar itens semelhantes (item-item) e/ou aplicar fatoração de matrizes para ranquear oportunidades.
RF05	Aplicar regras de negócio	Categorias essenciais não devem gerar recomendações de corte
RF06	Gerar recomendações	Cada recomendação deve conter título, categoria, impacto estimado em R\$, prioridade e explicação curta (máx. 2 frases).
RF07	Explicação detalhada	Ao clicar em “Entenda por quê”, o usuário deve visualizar fatores usados, período analisado e versão



		do modelo.
--	--	------------

Fonte: Elaborada pelo autor (2025)

4.4 Requisitos Não Funcionais

Os Requisitos Não Funcionais (RNF) definem características de qualidade e restrições que o módulo de recomendações deve atender para garantir desempenho, segurança, confiabilidade e usabilidade. Estes não descrevem o que o sistema faz, mas como ele deve funcionar em termos de velocidade de resposta, experiência do usuário, conformidade com legislações (como a LGPD) e boas práticas de desenvolvimento. No contexto do *FinancePro*, esses requisitos são essenciais para assegurar que o módulo de recomendações funcione corretamente.

Tabela 4 - Requisitos não funcionais do sistema

ID	Requisito	Descrição / Critérios de Aceite
RNF01	Usabilidade	A interface deve ser clara, em português, e seguir critérios de acessibilidade WCAG 2.1 nível AA.
RNF02	Observabilidade	O sistema deve manter logs estruturados, métricas de uso (requisições, erros) e permitir monitoramento contínuo.
RNF03	Manutenibilidade	O código deve ser desenvolvido em TypeScript, com cobertura de testes unitários de pelo menos 70% no núcleo do sistema, seguindo padrões de lint e formatação.
RNF04	Disponibilidade	A aplicação deve estar disponível em pelo menos 70% dia, para que consiga estar disponível para usuário, mas também não gere grande tráfego e acúmulo de tarefas de informação.

Fonte: Elaborada pelo autor



4.5 Modelagem do Sistema: Diagramas de Casos de Uso, Atividade, Classes e ER

Esta seção descreve, de forma visual e descritiva, como o usuário irá interagir com o sistema após a inclusão do módulo de recomendações e como os processos internos acontecem.

O diagrama de casos de uso mostra os principais objetivos do usuário e dos sistemas envolvidos. Já os diagramas de atividade detalham o fluxo das ações desde a análise das transações até a interação com cada recomendação.

4.5.1 Atores

O projeto, propõe dois atores principais:

1. **Usuário:** É o indivíduo que utiliza o sistema para gerenciar suas finanças pessoais, visualizar transações e interagir com as recomendações financeiras.
2. **Motor de Recomendação (IA):** Representa o serviço de **Inteligência Artificial (IA)** que gera as recomendações com base nas transações financeiras do usuário. O motor é responsável por analisar os dados e sugerir ações de economia.
3. **Sistema (Web/App):** Representa o sistema que o usuário visualiza, que irá receber a recomendação para ser exposta para o usuário.

4.5.2 Casos de uso

Os casos de uso representam os principais objetivos do usuário e os processos internos que o sistema executa. Abaixo estão os casos de uso relevantes para a interação do usuário com o sistema:

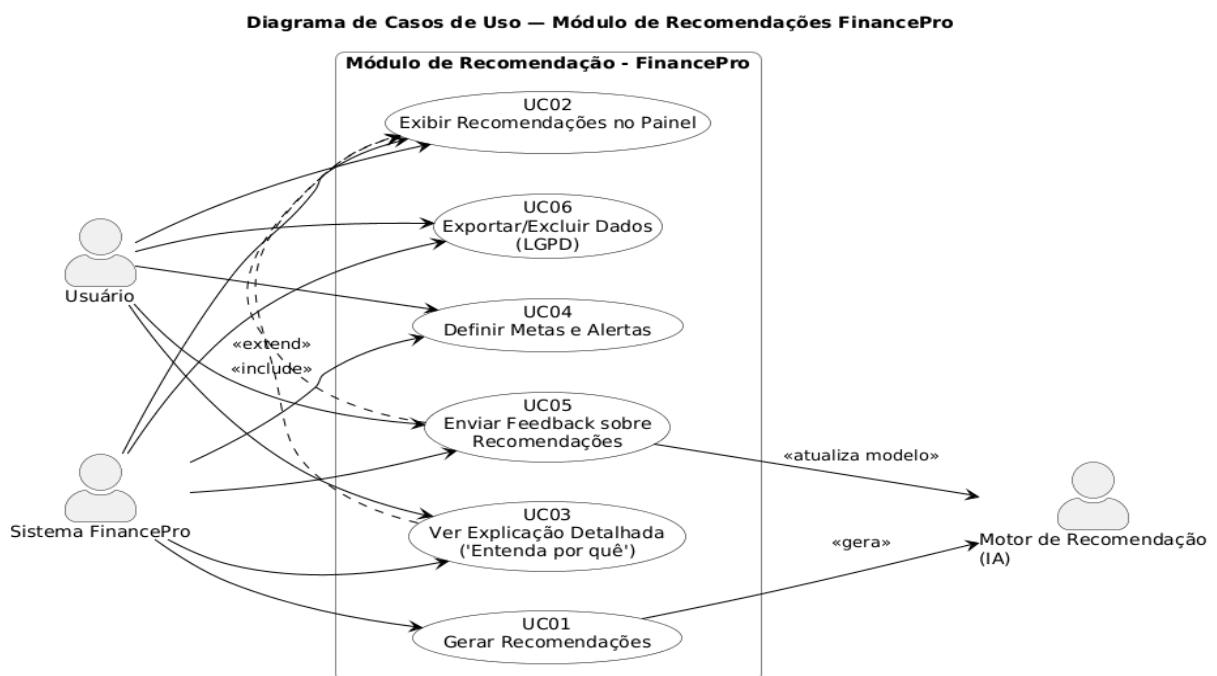
- **UC01 - Gerar Recomendações:** Processo automatizado pelo motor de IA para gerar sugestões de economia ou corte de gastos com base nas transações do usuário.
- **UC02 - Exibir Recomendações no Painel:** Exibição das recomendações geradas pelo motor de IA diretamente no painel do usuário, para visualização e interação.

- **UC03 - Ver Explicação Detalhada (“Entenda por quê”):** O usuário pode clicar em uma recomendação para ver detalhes explicando o motivo pelo qual foi sugerida.
- **UC04 - Definir Metas e Alertas:** O usuário pode definir suas metas financeiras (como cortar gastos em uma categoria específica) e configurar alertas para ser notificado sobre o progresso.

4.5.3 Diagramas de Casos de Uso

O diagrama de casos de uso apresentado a seguir tem como objetivo representar, de forma geral, as interações entre o usuário, o sistema proposto e o motor de Inteligência Artificial responsável pelas recomendações financeiras. Ele descreve as principais funcionalidades envolvidas no módulo de recomendações, evidenciando como o usuário se relaciona com o sistema e como este, por sua vez, se comunica com o agente de IA para gerar, exibir e aprimorar sugestões de economia. Essa representação auxilia na compreensão dos papéis de cada ator dentro do fluxo de uso, servindo como base para o entendimento funcional do sistema.

Figura 5 - Diagrama de Casos de Uso Sistema de Recomendação



Fonte: Elaborada pelo Autor

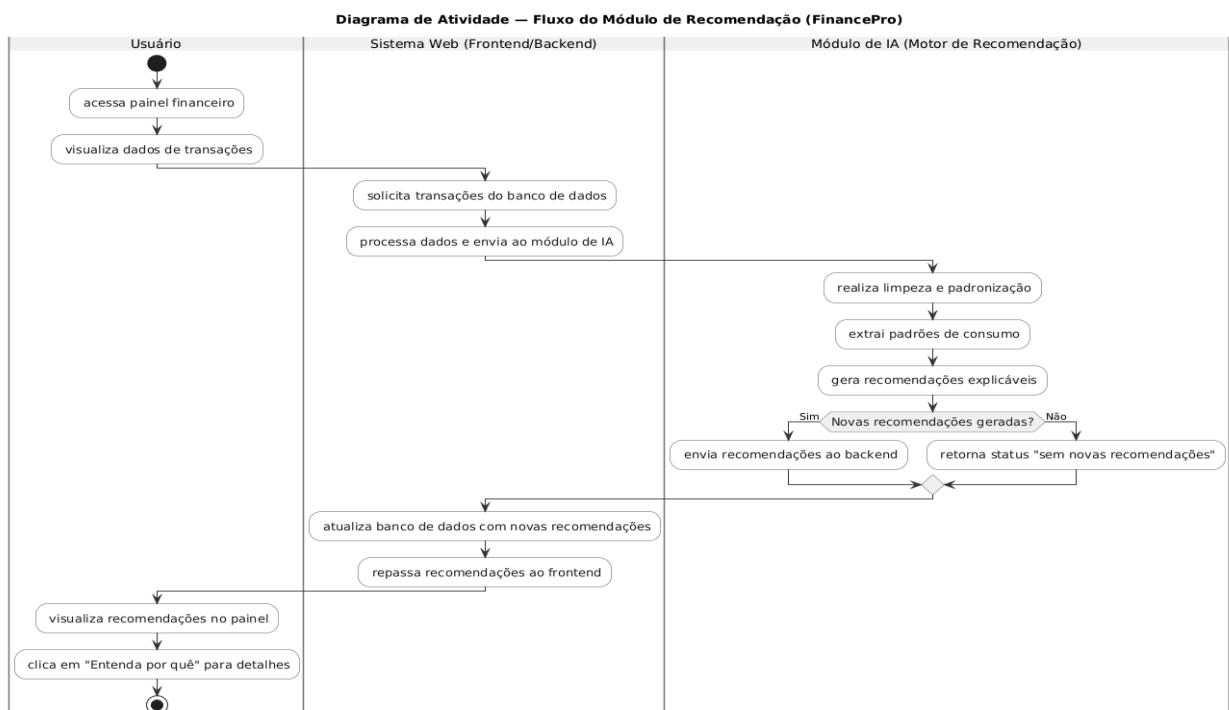
A partir do diagrama, é possível observar que o sistema atuará como intermediário entre o usuário e o motor de IA, centralizando as interações e garantindo a explicação das recomendações apresentadas. O usuário é capaz de visualizar suas sugestões, compreender o motivo por trás de cada uma, definir metas e fornecer feedbacks que retornam ao motor de IA para aprimorar o modelo.

4.5.4 Diagramas de Atividade

Os diagramas de atividade são uma forma de modelagem visual usada na UML (*Unified Modeling Language*) para representar fluxos de trabalho ou processos dentro de um sistema. Eles descrevem como as ações acontecem ao longo do tempo, mostrando o início, as decisões, os caminhos alternativos e o fim de uma atividade.

No contexto do projeto, os diagramas de atividade auxiliam a detalhar como as recomendações são geradas a partir das transações existentes e como o usuário pode interagir com elas, como demonstrado no diagrama a seguir.

Figura 6 - Diagrama de Atividades Recomendação Financeira



Fonte: Elaborado pelo autor (2025)



Por meio desse fluxo, é possível compreender a lógica interna do módulo de recomendação: o usuário realiza o acesso e visualiza suas transações, o sistema interage com o agente de IA por meio de webhooks, e este realiza o processamento das informações para gerar recomendações e retorná-las ao painel do usuário. Além disso, o diagrama evidencia o ciclo de aprendizado contínuo — o feedback do usuário é analisado pelo agente de IA, que ajusta seus modelos e heurísticas para aprimorar futuras recomendações. Essa representação visual demonstra a integração entre as camadas e reforça o caráter dinâmico e explicável da solução proposta.

4.5.5 Diagrama de Atividade: Geração de Recomendações

1. **Início:** O usuário acessa a plataforma e visualiza suas transações financeiras.
2. **Análise das Transações:** O motor de IA analisa os dados de transações, identificando padrões de consumo e comportamentos financeiros.
3. **Identificação de Oportunidades de Economia:** O sistema detecta áreas de gasto excessivo (exemplo: delivery, entretenimento) e cria recomendações baseadas nos objetivos do usuário.
4. **Geração de Recomendações:** O motor de IA gera as recomendações financeiras personalizadas, como “reduza 20% dos gastos com delivery para economizar R\$ 150/mês”.
5. **Decisão:** O usuário visualiza a recomendação no painel e decide interagir com ela.
 - Se o usuário clicar para ver mais detalhes (explicação), o processo segue para o **Diagrama de Atividade: Visualizar Explicação Detalhada**.
 - Se o usuário optar por definir metas ou alertas, o processo segue para a definição de metas.

4.5.6 Diagrama de Atividade: Visualizar Explicação Detalhada

1. **Início:** O usuário clica em uma recomendação para obter uma explicação detalhada.



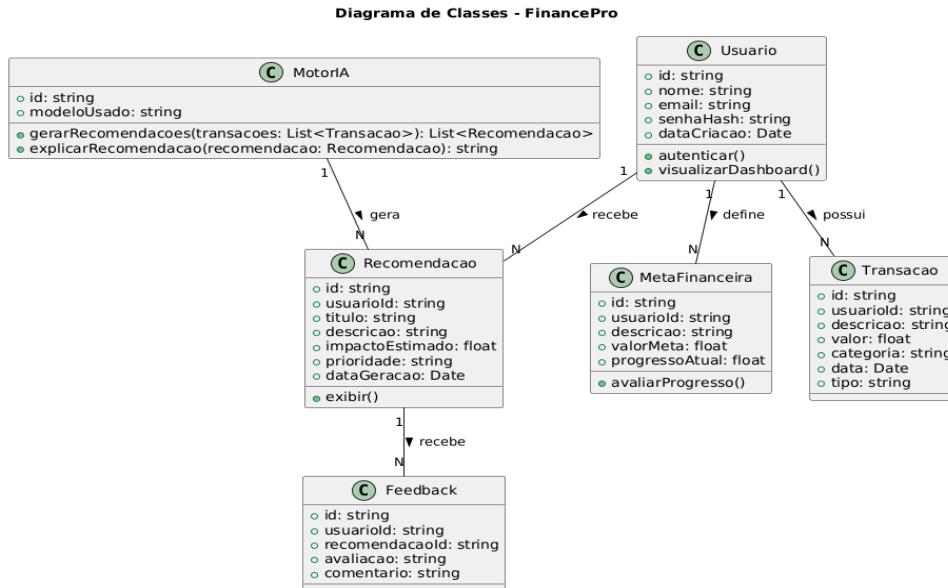
2. **Exibição da Explicação:** O sistema exibe os fatores que levaram à recomendação, como o histórico de transações e a comparação com o orçamento.
3. **Decisão:**
 - Se o usuário concorda com a recomendação, ele pode confirmar ou seguir com a ação sugerida.
 - Se o usuário não concorda, ele pode rejeitar a recomendação ou ajustá-la manualmente.
4. **Finalização:** O usuário pode continuar com o uso da plataforma ou sair da seção de recomendações.

4.5.7 Diagramas de Classe

O diagrama de classes é um dos principais artefatos da modelagem orientada a objetos e representa a estrutura estática do sistema. Ele descreve as classes, seus atributos, métodos e os relacionamentos existentes entre estas, sendo fundamental para compreender a arquitetura lógica do sistema, pois serve como base para a implementação do código, ajudando a manter coerência entre o projeto conceitual e o desenvolvimento real.

No contexto do projeto, o diagrama de classes demonstra a organização do sistema em torno de entidades centrais, como Usuário, Transação, Recomendação, MetaFinanceira e Feedback, além do componente MotorIA. Essa estrutura está evidenciada no diagrama a seguir.

Figura 6 - Diagrama de Classe



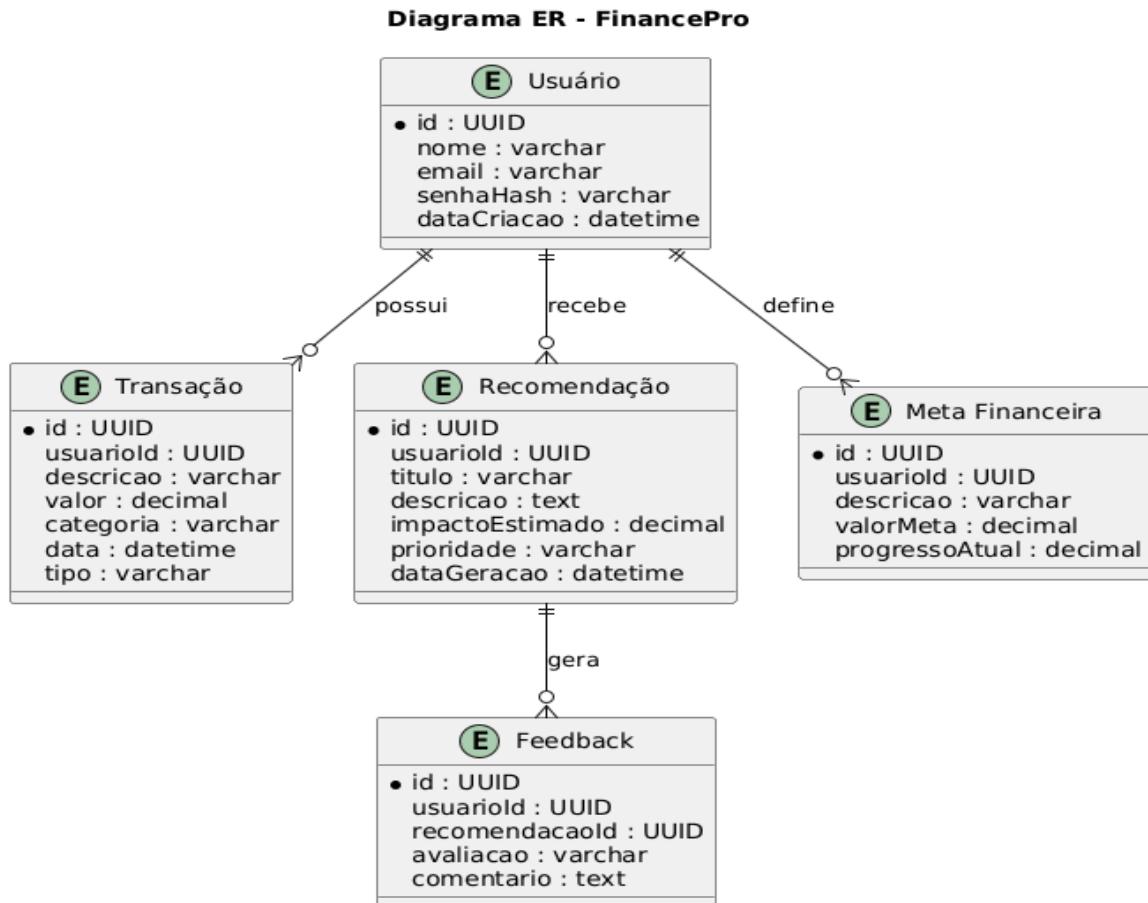
Fonte: Elaborado pelo autor (2025)

O diagrama elaborado para o projeto mostra de forma clara as associações “um-para-muitos” (1:N) entre as entidades principais, ilustrando as informações fluem dentro do módulo de recomendação a partir de uma modularização dos componentes.

4.5.8 Diagrama ER

O diagrama entidade-relacionamento (ER) é utilizado para representar o modelo lógico de dados de um sistema, evidenciando as entidades que compõem o banco de dados e os relacionamentos entre elas. Esse tipo de diagrama é amplamente aplicado no projeto de bancos de dados relacionais, pois auxilia na visualização da estrutura das tabelas, dos atributos e das chaves primárias e estrangeiras, isso tudo evidenciado no diagrama a seguir.

Figura 7 - Diagrama ER



Fonte: Elaborada pelo autor (2025)

O diagrama ER gerado demonstra um modelo relacional otimizado, no qual as relações entre as entidades são estabelecidas por meio de chaves estrangeiras. Essa modelagem favorece a consistência dos dados e permite que o módulo de IA acesse e processe as informações de forma estruturada, reduzindo redundâncias e aumentando a precisão das recomendações. Assim, o diagrama ER reforça a importância de uma base de dados bem projetada como alicerce técnico para o funcionamento do sistema de recomendação e para a confiabilidade dos resultados apresentados ao usuário.

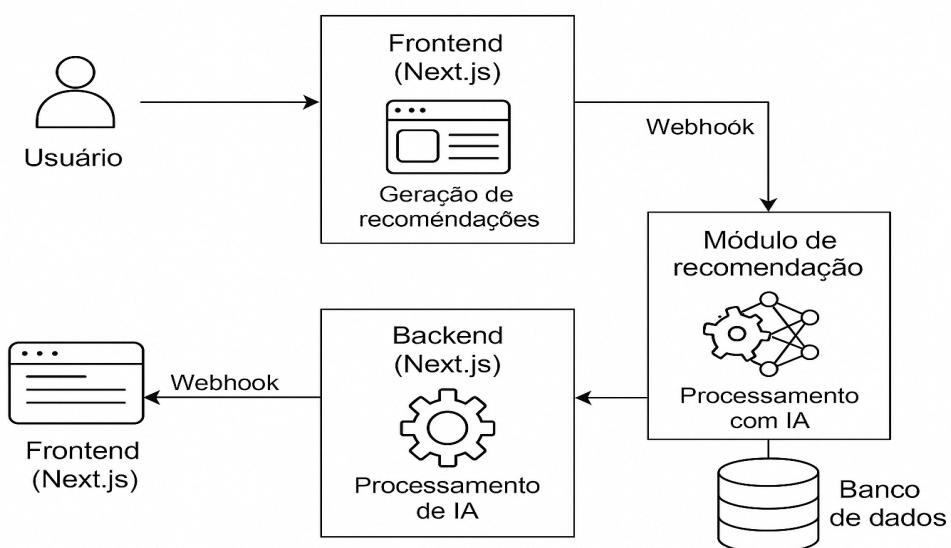
4.6 Arquitetura do Sistema

A arquitetura foi planejada para criação do módulo de recomendações, garantindo desempenho e manutenibilidade. Este capítulo descreve como os principais elementos de software se organizam e se comunicam, detalhando desde a visão geral de contexto até os componentes internos.

A arquitetura foi pensada para ser modular e evolutiva. O módulo de recomendação pode ser ampliado ou substituído sem afetar as demais camadas, e o módulo com a tecnologia *fullstack* do *Next.js* entre frontend e backend permite escalabilidade horizontal. Além disso, o respeito a requisitos não funcionais — como segurança (LGPD), desempenho (tempo de resposta) e observabilidade (logs e métricas) — foi considerado como parte essencial do desenho da solução.

Na visão de contexto, o projeto é visto como um sistema que conecta usuário final e módulo de recomendações dentro de um fluxo contínuo. O usuário acessa a plataforma via navegador, o frontend exibe dados e consome APIs internas, e o motor de IA gera recomendações com base nas transações já registradas.

Figura 7 - Arquitetura representativa do sistema de recomendação



Fonte: Elaborada pelo autor



O sistema, apresentado na Figura 5, segue uma abordagem web em camadas/módulos/componentes, composta por:

- **Frontend:** responsável pela interface com o usuário, renderizando páginas dinâmicas (SSR) e estáticas (SSG/ISR), e exibindo recomendações de forma integrada ao painel de finanças.
- **Backend (API Routes / Handlers):** camadas de serviços que processam dados, aplicam regras de negócio e conectam a interface ao módulo de recomendação.
- **Módulo de Recomendação (IA/ML):** serviço especializado que executa a mineração de dados, modelagem de padrões e geração das recomendações explicáveis.
- **Banco de Dados:** armazena usuários, transações, categorias, recomendações e feedbacks, garantindo integridade e histórico.

4.7 CRONOGRAMA

Tabela 5 - Cronograma do projeto

Período	Atividade	Descrição detalhada
15/01 a 31/01/2026	Planejamento da Arquitetura de IA e <i>Webhook</i>	Definir a arquitetura para integração do módulo de IA com o sistema, incluindo como as requisições serão feitas entre <i>frontend</i> , <i>backend</i> e IA. Planejar a criação de <i>webhooks</i> para comunicação entre o sistema e plataformas externas.
01/02 a 07/02/2026	Desenvolvimento do modelo de Algoritmo de IA.	Desenvolver os primeiros modelos de IA para análise de dados financeiros (ex: recomendação de corte de gastos).
08/02 a 14/02/2026	Estruturação do <i>backend</i> para receber um modelo de IA	Estruturar todo o servidor, para conseguir receber todas as novas requisições e uma integração com o modelo.
15/02 a 21/02/2026	Integração do <i>Backend</i> com o modelo de IA	Integrar o modelo com o <i>backend</i> para que o sistema possa gerar recomendações em tempo real.
22/02 a	Criação de <i>Webhooks</i>	Iniciar a criação de <i>webhooks</i> para



28/02/2026	para Integração de Automação		comunicação com sistemas externos, como APIs bancárias ou notificações externas, para enviar ou receber dados de transações financeiras e interagir com usuários.
01/03 a 07/03/2026	Automação Processos Implementação Chamadas API	de e de	Implementar rotinas automáticas no backend, como notificação de alertas de gastos, recomendações de ações financeiras. Integrar com API REST para gerenciar requisições entre <i>frontend</i> e <i>backend</i> , incluindo chamadas para o módulo de IA.
08/03 a 14/03/2026	Testes Iniciais do Módulo de IA		Realizar testes iniciais no módulo de IA para garantir que as recomendações financeiras são geradas corretamente com base nas transações financeiras dos usuários. Ajustar os modelos conforme necessário, validando a partir das necessidades tanto do serviço, quanto do modelo de IA
15/03 a 21/03/2026	Otimização Chamadas Requisição Performance	das de e	Realizar otimizações na arquitetura das chamadas de requisição para garantir alta performance. Ajustar os <i>endpoints</i> da API para suportar grandes volumes de dados financeiros de maneira eficiente.
22/03 a 31/03/2026	Testes de Usuários e Ajustes Finais		Realizar testes finais com usuários reais para validar a utilidade das recomendações e a eficiência da integração com o módulo de IA e a automação via webhooks. Ajustes conforme o feedback dos testes.
01/04 a 10/04/2026	Documentação Técnica e Preparação para testes em massa		Elaborar a documentação técnica detalhada sobre a arquitetura de IA, automações implementadas e a integração via webhooks. Preparar a defesa com foco nas integrações e no desenvolvimento do módulo de IA.
11/04 a 20/04/2026	Finalização Documentação lançamento produção	da em	Realizar ajustes finais na documentação técnica e na implementação do módulo de IA, além de ajustes finais para o lançamento

Fonte: Elaborada pelo autor (2025)



5. CONSIDERAÇÕES

O presente trabalho de conclusão de curso estabelece as bases teóricas, metodológicas e de projeto para o desenvolvimento de um Sistema de Recomendação Financeira Pessoal Inteligente.

A etapa de pesquisa resultou em um Referencial Teórico, que fundamenta a aplicação de Agentes de Inteligência Artificial e Aprendizado por Reforço no contexto da mitigação de gastos desnecessários. O planejamento do projeto foi consolidado por meio de uma Metodologia e da elaboração de artefatos de projeto essenciais, como os Diagramas UML (Casos de Uso, Atividade) e a Arquitetura do Sistema, que definem a estrutura técnica da solução. Desta forma, o projeto demonstra viabilidade técnica e sua relevância, cumprindo a finalidade da proposta.

Como continuidade, o próximo passo será a implementação e validação empírica do sistema. Esta fase envolverá o desenvolvimento da estrutura base e do módulo de recomendação, com a construção do protótipo e a realização de testes de usabilidade e eficácia para comprovar o impacto da solução na gestão financeira pessoal.



REFERÊNCIAS

BANCO CENTRAL DO BRASIL. **Relatório da OCDE avalia letramento financeiro entre adolescentes de 20 economias mundiais.** Brasília: BCB, 5 set. 2024. Disponível em:
<https://aprendervalor.bcb.gov.br/site/aprendervalor/NoticiaAprenderValor/100/noticia>. Acesso em: 1 set. 2025.

COSTA, Evandro; AGUIAR, Janderson; MAGALHÃES, Jonathas. **Sistemas de Recomendação de Recursos Educacionais: conceitos, técnicas e aplicações.** In: JORNADA DE ATUALIZAÇÃO EM INFORMÁTICA NA EDUCAÇÃO (JAIE), 2013. Anais... Porto Alegre: SBC, 2013. p. 57–78. DOI: 10.5753/CBIE.JAIE.2013.57. Disponível em: <http://www.br-ie.org/pub/index.php/pie/article/view/2589>. Acesso em: 1 set. 2025.

DI FANTE, Artur Lunardi. *Collaborative-based recommendation system using SVD*. Medium, 2020. Disponível em: [https://medium.com/analytics-vidhya/collaborative-based-recommendation-system-usin g-svd-9adc5b6b3b8](https://medium.com/analytics-vidhya/collaborative-based-recommendation-system-using-svd-9adc5b6b3b8). Acesso em: 16 nov. 2025.

FERRO, J. E. **Sistemas de recomendação: uma abordagem conceitual.** 2010. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Universidade Federal de Santa Catarina, Florianópolis, 2010.

GOOGLE CLOUD. IA em finanças: aplicativos, exemplos e benefícios. Disponível em: <https://cloud.google.com/discover/finance-ai?hl=pt-BR>. Acesso em: 16 set. 2025.

IYENGAR, Sheena S.; LEPPER, Mark R. **When choice is demotivating: Can one desire too much of a good thing?** *Journal of Personality and Social Psychology*, v. 79, n. 6, p. 995–1006, 2000. DOI: 10.1037/0022-3514.79.6.995.

KAYA, T. S.; GEZER, M.; GÜLSEÇEN, S. **Application of Recommender System for Spending Habits Based Campaign Management.** *Proceedings*, v. 74, n. 1, art. 7, 2021. DOI: 10.3390/proceedings2021074007.

LINDEN, G.; SMITH, B.; YORK, J. **Amazon.com recommendations: item-to-item collaborative filtering.** *IEEE Internet Computing*, v. 7, n. 1, p. 76–80, 2003. Disponível em: <https://ieeexplore.ieee.org/document/1167344>. Acesso em: 16 set. 2025.

NEXT.JS. *Server-side Rendering (SSR).* Disponível em: <https://nextjs.org/docs/pages/building-your-application/rendering/server-side-rendering>. Acesso em: 17 set. 2025. [Next.js](#)

NEXT.JS. *Static Site Generation (SSG).* Disponível em: <https://nextjs.org/docs/pages/building-your-application/rendering/static-site-generation>. Acesso em: 17 set. 2025. [Next.js](#)



NEXT.JS. *How to implement Incremental Static Regeneration (ISR) – App Router.* Disponível em: <https://nextjs.org/docs/app/guides/incremental-static-regeneration>. Acesso em: 17 set. 2025. [Next.js](#)

ORGANISATION FOR ECONOMIC CO-OPERATION AND DEVELOPMENT (OECD). **PISA 2022 Results (Volume IV): Students' Financial Literacy.** Paris: OECD Publishing, 2024. Disponível em: https://www.oecd.org/en/publications/pisa-2022-results-volume-iv_5a849c2a-en.html. Acesso em: 1 set. 2025.

QUADRANA, M.; CREMONESI, P.; JANNACH, D. **Sequence-Aware Recommender Systems.** *ACM Computing Surveys*, v. 51, n. 4, art. 66, 2018.

RESNICK, P.; VARIAN, H. R. Recommender systems. **Communications of the ACM**, v. 40, n. 3, p. 56-58, 1997.

SARWAR, B.; KARYPIS, G.; KONSTAN, J.; RIEDL, J. **Item-Based Collaborative Filtering Recommendation Algorithms.** In: *Proceedings of WWW10*. New York: ACM, 2001. p. 285–295.

SOUZA, Evandro F. *Sistemas de recomendação.* Medium, 2019. Disponível em: <https://medium.com/tech-grupozap/sistemas-de-recomenda%C3%A7%C3%A3o-5bd1626326fe>. Acesso em: 16 nov. 2025.

TAKAHASHI, E. K.; JUNIOR, J. R. B. **Sistemas de recomendação: conceitos, técnicas, aplicações e tendências.** *Revista de Informática Teórica e Aplicada*, Porto Alegre, v. 22, n. 2, p. 110–134, 2015. DOI: 10.22456/2175-2745.56125.

WEB.DEV (Google). *Rendering on the Web.* Disponível em: <https://web.dev/articles/rendering-on-the-web>. Acesso em: 17 set. 2025.

ZHANG, Y.; CHEN, X. **Explainable Recommendation: A Survey and New Perspectives.** *Foundations and Trends in Information Retrieval*, v. 14, n. 1, p. 1–101, 2020. DOI: 10.1561/1500000066.

ZIBRICZKY, D. **Recommender Systems Meet Finance: A Literature Review.** In: PROCEEDINGS OF THE 2ND INTERNATIONAL WORKSHOP ON PERSONALIZATION AND RECOMMENDER SYSTEMS IN FINANCIAL SERVICES. Aachen: CEUR-WS, v. 1606, 2016. Disponível em: <https://ceur-ws.org/Vol-1606/paper02.pdf>. Acesso em: 16 set. 2025.